

haAldra

Rapport de Selection des Donnees
et Plan d Implementation

Pipeline IA d Analyse Automatique des Appels de Centre de Contact

Support bilingue : Francais et Anglais
Document de Reference Academique - April 2026
Version 1.0 - Usage Recherche et Developpement

Resume

Ce rapport presente la strategie de selection des jeux de donnees et la feuille de route d implementation pour haAldra, un pipeline d intelligence artificielle destine a analyser automatiquement les conversations de centres de contact en anglais et en francais. Le systeme realise cinq operations principales : le traitement des transcriptions, la detection du sentiment, la classification des sujets, la generation de resumes, et la notation de la performance des agents. Etant donne qu aucun jeu de donnees public unique ne fournit l ensemble des etiquettes requises dans les deux langues, ce document detaille une strategie combinant plusieurs sources complementaires. Chaque jeu de donnees est decrit en termes d origine, de volume, de licence, de structure et de role precis dans le pipeline haAldra. Un plan d implementation complet est fourni sous forme de sequence ordonnee de dix etapes executables, chacune accompagnee du code Python correspondant.

Mots-cles

traitement du langage naturel, pipeline IA bilingue, analyse de transcriptions, detection de sentiment, notation d agents, affinage de GPT, NLP francais, CamemBERT, strategie de donnees.

1. Vue d ensemble de l architecture du pipeline

haAldra est structure en couches NLP sequentielles. Chaque couche depend de la sortie de la precedente. Comprendre cette dependance est essentiel avant de selectionner les jeux de donnees, car chaque source doit couvrir au moins une couche du pipeline.

Couche	Entree	Sortie	Type de modele
1 - Transcription	Lignes brutes (locuteur, texte)	Conversation complete nettoye	Regroupement par regle
2 - Sentiment	Transcription complete	Positif / Neutre / Negatif + score	Pre-entraine ou affine
3 - Sujet / Intention	Transcription complete	Liste de sujets ou intentions	GPT affine ou classifieur
4 - Resume	Transcription complete	Resume en 2-3 phrases	GPT-4o par prompt
5 - Note de l agent	Transcription complete	Note 1-10 + justification	GPT-4o-mini affine
6 - Controle qualite	Note + resume	Valide / Signale / Escalade	Regles + GPT
7 - Notification	Resultat QA	Alerte superviseur	Signal Django

Tableau 1 - Couches du pipeline haAldra, entrees, sorties et types de modeles.

2. Jeux de donnees selectionnes - Descriptions detaillees

Les cinq jeux de donnees suivants ont ete selectionnes pour couvrir toutes les couches du pipeline haAldra en anglais et en francais. Chaque jeu de donnees est presente avec ses metadonnees completes, sa description structurelle et son role precis dans le systeme.

2.1 Corpus de transcriptions anglaises

AlxBLOCK / 92 000 Scripts Reels de Centres de Contact (Anglais)		EN	
Source	AlxBLOCK - Partenariats avec des centres BPO (Inde, Philippines, Etats-Unis)	Volum e	91 706 conversations - environ 10 500 heures equivalentes
Licence	CC BY-NC 4.0 - gratuit pour la recherche, redistribution commerciale interdite	Acces	huggingface.co/datasets/AlxBLOCK/92k-real-world-call-center-scripts-english

Le plus grand corpus public de transcriptions de centres de contact en anglais. Les conversations couvrent le support client entrant et sortant dans plusieurs secteurs. Toutes les informations personnelles identifiables (PII) ont ete supprimees selon une taxonomie de 40 categories (noms, numeros de telephone, numeros de compte, dates, etc.). Les transcriptions sont stockees en format JSON individuel avec des horodatages au niveau du mot et des scores de confiance ASR. La precision de transcription est estimee a 96,13 % sur un sous-ensemble evalue manuellement. Ce corpus reflète directement le type de donnees que haAldra traitera en production.

Colonnes / Champs : conversation_id, locuteur, texte, horodatages, confiance, domaine, type_appel (entrant/sortant)

Utilise pour : Couche 1 (Transcription), Couche 3 (Extraction de sujets), Couche 5 (Etiquetage automatique pour la notation)

2.2 Corpus de transcriptions francaises

AxonData / Jeu de Donnees Audio Centre de Contact
Francais

FR EN

Source	AxonData - Enregistrements telephoniques reels en francais	Volum e	Plus de 1 000 heures audio - transcriptions completes en FR et EN
Licenc e	Acces recherche via HuggingFace - contacter AxonData	Acces	huggingface.co/datasets/AxonData/french-call-center-speech-datas et

Un jeu de donnees reel de centre de contact francais comprenant des appels entrants et sortants. Contrairement a la plupart des ressources NLP francaises, ce corpus provient d interactions telephoniques authentiques et non de textes synthetiques. Chaque enregistrement est accompagne de deux versions de transcription : le francais original et une traduction anglaise. Cette structure bilingue le rend directement utilisable pour l entrainement et l evaluation multilingue. Le corpus couvre les domaines du support client, de la vente et de la facturation.

Colonnes / Champs : audio_id, transcription_fr, transcription_en, type_appel, domaine, duree_secondes

Utilise pour : Couche 1 (Transcriptions FR), Couche 2 (Etiquetage sentiment FR), Couche 3 (Extraction sujets FR)

2.3 Jeu de donnees pour la classification d intentions

Bitext / Jeu de Donnees d Entrainement Chatbot Support Client LLM

EN

Source	Bitext Innovations - generation hybride NLP/NLG, curation par des linguistes	Volum e	27 000 paires instruction-reponse - 3,57 millions de tokens
Licenc e	CDLA-Sharing 1.0 - gratuit, partage sous meme licence	Acces	huggingface.co/datasets/bitext/Bitext-customer-support-llm-chatbot-training-dataset

Un corpus professionnel concu specifiquement pour l'affinage de grands modeles de langage dans le domaine du support client. Il couvre 27 intentions distinctes organisees en 10 categories semantiques, notamment : annuler_commande, reclamation, contacter_agent, remboursement, probleme_paiement, suivre_commande. Chaque intention contient environ 1 000 exemples. Le corpus inclut des etiquettes de variation linguistique (FAMILIER, FORMEL, OFFENSANT) qui refletent les patterns de discours reel, rendant les modeles entraines robustes au langage informel. Il a ete utilise par Bitext pour affiner Mistral-7B en modele de support client en production. Note : aucune version francaise native n'existe. La strategie recommandee est de le traduire via GPT-4o en mode batch.

Colonnes / Champs : instruction (requete utilisateur), reponse (reponse agent), intention, categorie, drapeaux (variations linguistiques)

Utilise pour : Couche 3 (Affinage de GPT-4o-mini pour la classification d'intentions)

2.4 Modele de sentiment multilingue (EN + FR, sans entrainement)

nlptown / bert-base-multilingual-uncased-sentiment		EN FR DE ES IT NL	
Source	NLP Town - affine sur des avis produits en 6 langues	Volum e	Modele pre-entraîne - environ 110 millions de parametres - aucun entraînement supplémentaire requis
Licence	MIT - entierement ouvert, usage commercial autorise	Acces	huggingface.co/nlptown/bert-base-multilingual-uncased-sentiment

Un classificateur de sentiment multilingue base sur BERT, affine sur des avis produits en anglais, français, neerlandais, allemand, espagnol et italien. Il produit une note de 1 a 5 étoiles, qui correspond directement a l echelle de sentiment haAldra : 1-2 = negatif, 3 = neutre, 4-5 = positif. L avantage principal est la couverture bilingue sans configuration : il traite les transcriptions en anglais et en français avec un seul et meme modele, sans aucun affinage ni preparation de donnees. C est la voie la plus rapide pour disposer d une couche de sentiment fonctionnelle pour les deux langues simultanement.

Colonnes / Champs : Entree : chaine de texte brute. Sortie : etiquette (1-5 étoiles), score (confiance 0.0-1.0)

Utilise pour : Couche 2 (Detection de sentiment EN et FR sans entraînement)

2.5 Modele de sentiment natif francais (sentiment FR avance)

cmarkea / distilcamembert-base-sentiment		FR	
Source	CMarKEA - DistilCamemBERT affine sur Amazon Reviews FR + Allocine	Volum e	Pre-entraîne - environ 67 millions de parametres - 204 993 avis Amazon + 235 516 critiques Allocine
Licence	MIT - entierement ouvert	Acces	huggingface.co/cmarkea/distilcamembert-base-sentiment

Un modele de sentiment natif francais construit sur DistilCamemBERT, version allgee de CamemBERT (l equivalent francais de BERT). Il est entraîne sur deux sources textuelles francaises complementaires : les avis Amazon (courts, informels) et les critiques Allocine (longs, structures). Cette double source reduit les biais et ameliore la generalisation aux styles de texte varies, notamment les patterns de discours informel des transcriptions de centres de contact. La vitesse d inference est deux fois superieure a CamemBERT standard, ce qui le rend adapte a l analyse en temps reel. Produit 5 classes de sentiment : tres negatif, negatif, neutre, positif, tres positif.

Colonnes / Champs : Entree : chaine de texte en francais. Sortie : etiquette (1-5), score (confiance 0.0-1.0)

Utilise pour : Couche 2 (Sentiment FR - precision superieure au modele multilingue pour les appels en francais uniquement)

3. Tableau de couverture par langue et par couche

Le tableau ci-dessous indique quel jeu de donnees couvre chaque couche du pipeline pour chaque langue. Les couches marquees 'Etiquetage GPT' ne necessitent aucune source externe : GPT-4o genere les etiquettes directement depuis les transcriptions existantes.

Couche du pipeline	Anglais (EN)	Francais (FR)
1 - Transcriptions	AlxBLOCK 92k	AxonData French
2 - Sentiment	nlptown/bert-multilingual	nlptown/bert-multilingual ou cmarkea/distilcamembert
3 - Sujets / Intentions	Bitext 27k intentions	Bitext traduit EN->FR via GPT-4o batch
4 - Resume	Prompt GPT-4o (pas de donnees)	Prompt GPT-4o en francais
5 - Note de l agent	Etiquetage GPT-4o -> affinage	Etiquetage GPT-4o -> affinage
6 - Controle qualite	Regles + GPT-4o	Regles + GPT-4o
7 - Notification	Signal Django (pas d IA)	Signal Django (pas d IA)

Tableau 2 - Couverture bilingue des jeux de donnees par couche du pipeline.

4. Plan d implementation - Checklist ordonnee en 10 etapes

Les etapes suivantes doivent etre executees dans l ordre indique. Chaque etape est autonome et produit un resultat verifiable avant de passer a la suivante. Ne pas sauter d etapes.

01

Installer toutes les bibliotheques Python requises

- Executer cette commande une seule fois dans votre environnement de projet.
- Installe : HuggingFace datasets, SDK OpenAI, Transformers et Django REST.

```
pip install datasets openai transformers torch django djangorestframework
```

02

Telecharger le corpus anglais (AIXBlock 92k transcriptions)

- Charger le jeu de donnees depuis HuggingFace - aucun compte requis.
- Afficher le premier enregistrement pour verifier la structure des colonnes.
- Colonnes attendues : conversation_id, locuteur, texte, domaine, type_appel.

```
from datasets import load_dataset ds =  
load_dataset('AIXBlock/92k-real-world-call-center-scripts-english') print(ds)  
print(ds['train'][0])
```

03

Telecharger le corpus francais (AxonData)

- Charger le jeu de donnees de centre de contact francais.
- Ce jeu contient les colonnes transcription_fr et transcription_en.
- Utiliser transcription_fr pour les tests du pipeline en francais.

```
fr_ds = load_dataset('AxonData/french-call-center-speech-dataset')  
print(fr_ds['train'][0]['transcript_fr'])
```

04

Telecharger le jeu de donnees d intentions (Bitext 27k)

- Charger les 27 000 paires d intentions pour l affinage de la couche de classification.
- Examiner les champs instruction, reponse et intention.
- Ce jeu sera utilise pour affiner GPT-4o-mini a l etape 8.

```
intents = load_dataset(
    'bitext/Bitext-customer-support-llm-chatbot-training-dataset' )
print(intents['train'][0]) # Champs : instruction, response, intent, category,
flags
```

05

Regrouper les transcriptions par conversation_id

- Votre jeu Kaggle et AlxBLOCK stockent une ligne par utterance.
- Il faut regrouper toutes les lignes par conversation_id pour obtenir un appel complet.
- Resultat : un dictionnaire par appel avec une transcription complete en texte brut.

```
import pandas as pd df = pd.read_csv('votre_dataset_kaggle.csv') conversations =
{} for _, row in df.iterrows(): cid = row['conversation_id'] if cid not in
conversations: conversations[cid] = [] conversations[cid].append(
f"{row['speaker']}: {row['text']}" ) dataset = [ {'id': cid, 'transcript':
chr(10).join(turns)} for cid, turns in conversations.items() ] print(f'Total
appels : {len(dataset)}') print(dataset[0]['transcript'][:300])
```

06

Configurer le modele de sentiment multilingue (EN + FR)

- Charger le modele BERT de nlptown - fonctionne pour l anglais et le francais immediatement.
- Tester sur une transcription anglaise et une transcription francaise.
- Aucun entraînement requis. Correspondance : 1-2 etoiles = negatif, 3 = neutre, 4-5 = positif.

```
from transformers import pipeline sentiment_model = pipeline(
'sentiment-analysis', model='nlptown/bert-base-multilingual-uncased-sentiment' ) #
Test anglais print(sentiment_model('The agent was very helpful')) # Test francais
print(sentiment_model('L agent etait tres professionnel'))
```

07

Etiqueter automatiquement 100 appels avec GPT-4o (sentiment + sujets + resume + note)

- Definir votre cle API OpenAI dans le fichier .env.
- Executer cette fonction sur 100 appels pour generer les etiquettes de reference.
- Verifier manuellement 10 a 20 resultats pour valider la qualite des sorties GPT.
- Ces etiquettes constituent votre jeu de donnees d affinage pour l etape suivante.

```
import os, json from openai import OpenAI client =
OpenAI(api_key=os.getenv('OPENAI_API_KEY')) def analyser(transcript, langue='fr'):
prompt_sys = ( 'Tu analyses des conversations de centre de contact ' 'en francais
et en anglais. ' 'Retourne un JSON : {sentiment, score_sentiment, ' 'sujets,
resume, note_agent, resolution}' ) r = client.chat.completions.create(
model='gpt-4o', response_format={'type': 'json_object'}, messages=[ {'role':
'system', 'content': prompt_sys}, {'role': 'user', 'content': transcript} ])
return json.loads(r.choices[0].message.content) etiquetes = [] for appel in
dataset[:100]: res = analyser(appel['transcript']) etiquetes.append({'appel',
**res}) print(f"Note : {appel['id']} -> {res['note_agent']}")
```

08

Construire le fichier JSONL et affiner GPT-4o-mini pour la notation

- Convertir les 100 appels etiquetes au format d affinage OpenAI.
- Televerser le fichier JSONL et lancer un job d affinage.
- Attendre 15 a 30 minutes - OpenAI vous envoie un email a la fin.
- Sauvegarder l identifiant du modele affine pour l etape 9.

```
import json with open('affinage_notation.jsonl', 'w') as f: for appel in
etiquetes: record = {'messages': [ {'role': 'system', 'content': 'Tu notes les
conversations de centre de contact.'}, {'role': 'user', 'content':
appel['transcript']}, {'role': 'assistant', 'content': json.dumps({ 'note_agent':
appel['note_agent'], 'resolution': appel['resolution'] })} ]}
f.write(json.dumps(record) + chr(10)) fichier = client.files.create(
file=open('affinage_notation.jsonl', 'rb'), purpose='fine-tune' ) job =
client.fine_tuning.jobs.create( training_file=fichier.id, model='gpt-4o-mini' )
print(f'Job ID : {job.id}')
```

09

Construire la fonction complete du pipeline

- Combiner sentiment + resume + sujets + notation en une seule fonction.
- C est le coeur de haAldra - a appeler une fois par transcription.
- Remplacer VOTRE_MODEL_ID par l'identifiant du modele affine obtenu a l'etape 8.

```
MODELE_NOTATION = 'ft:gpt-4o-mini:votre-org::VOTRE_MODEL_ID' def
pipeline_complet(transcript, langue='fr'): sentiment =
sentiment_model(transcript[:512])[0] analyse = analyser(transcript, langue) note_r
= client.chat.completions.create( model=MODELE_NOTATION, messages=[ {'role':
'system', 'content': 'Note cet appel de centre de contact.'}, {'role': 'user',
'content': transcript} ]) note = json.loads(note_r.choices[0].message.content)
return { 'sentiment': sentiment['label'], 'sujets': analyse['sujets'], 'resume':
analyse['resume'], 'note_agent': note['note_agent'], 'resolution':
note['resolution'], }
```

10

Connecter le pipeline a Django et tester de bout en bout

- Creer un endpoint Django POST qui accepte une conversation et retourne l'analyse.
- Tester avec un appel reel via curl ou Postman.
- Verifier que les 5 champs de sortie apparaissent dans la reponse.
- Si tout passe - votre pipeline MVP est fonctionnel.

```
# views.py from django.http import JsonResponse import json def
analyser_appel(request): if request.method == 'POST': data =
json.loads(request.body) transcript = data['transcript'] langue =
data.get('langue', 'fr') resultat = pipeline_complet(transcript, langue) return
JsonResponse({'statut': 'ok', 'resultat': resultat}) # urls.py from django.urls
import path from . import views urlpatterns = [ path('api/analyser/',
views.analyser_appel) ]
```

5. References et citations des jeux de donnees

- [1] AlxBLOCK (2025). Real-World English Call Centre Transcripts Dataset with PII Redaction. arXiv:2507.02958. Disponible : huggingface.co/datasets/AlxBLOCK/92k-real-world-call-center-scripts-english
- [2] AxonData (2024). French Call Centre Speech Dataset. HuggingFace Datasets. Disponible : huggingface.co/datasets/AxonData/french-call-center-speech-dataset
- [3] Bitext Innovations (2023). Bitext Customer Support LLM Chatbot Training Dataset. HuggingFace Datasets. Licence CDLA-Sharing 1.0. Disponible : huggingface.co/datasets/bitext/Bitext-customer-support-llm-chatbot-training-dataset
- [4] NLP Town (2021). bert-base-multilingual-uncased-sentiment. HuggingFace Model Hub. Licence MIT. Disponible : huggingface.co/nlptown/bert-base-multilingual-uncased-sentiment
- [5] Delestre, C. & Amar, A. (2022). DistilCamemBERT : une distillation du modele francais CamemBERT. CAp 2022 - Conference sur l Apprentissage automatique, Vannes, France. Modele : huggingface.co/cmarkea/distilcamembert-base-sentiment
- [6] OpenAI (2024). Affinage de GPT-4o-mini - Documentation Developpeur. Disponible : platform.openai.com/docs/guides/fine-tuning
- [7] Wolf, T. et al. (2020). Transformers : State-of-the-Art Natural Language Processing. Proceedings of EMNLP 2020. HuggingFace. Disponible : huggingface.co/transformers

Ce document est genere pour le projet de recherche haAldra. Tous les jeux de donnees references sont publiquement disponibles sous des licences ouvertes ou de recherche. L utilisation commerciale de chaque jeu de donnees doit respecter les termes de sa licence respective.